# BOMiS 단계별 SZ 회수와 STZ 억제 분석

Support Estimation → Probability Allocation → Generation

---

합성 데이터 실험 · 쉬운 상황 (Frequent)

# 실험 목적

원본 BOMiS의 SZ 회수와 STZ 억제가 생성 데이터까지 이어지는지 단계별로 본다

**1. Support Estimation**
가능한 minority 조합(SZ)을 얼마나 허용하고 불가능한 조합(STZ)을 얼마나 제거하는가

- SZ 허용 (질량·개수 회수)
- STZ 억제율

**2. Probability Allocation**
Good–Turing으로 새 행의 비율을, Chao1로 새 셀의 개수와 배분을 정한다

- 새 셀에 놓을 행 수
- 새 셀 개수 $L$

**3. Generation**
Transformer와 support 제약으로 실제 minority 행을 생성한다

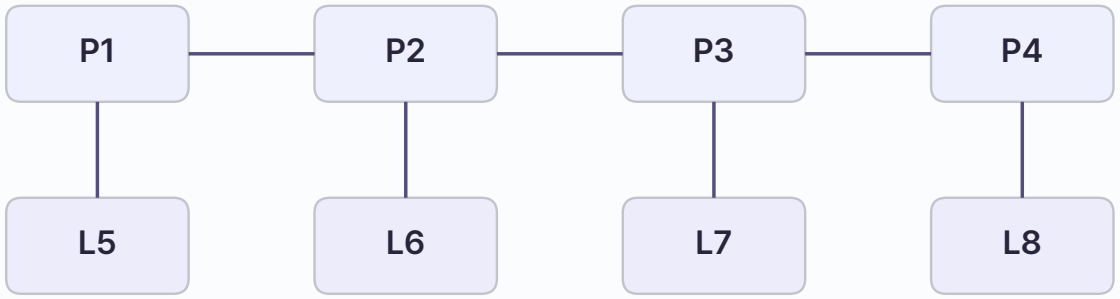
- 생성 행의 SZ 회수 (질량·개수)
- leak, control

**Support 추정 단계의 성능이 실제 생성 데이터까지 유지되는지 확인한다**

# 합성 데이터: Majority 분포 $p_0$

부모 4개·잎 4개 트리로 의존성을 두고, 모든 셀 확률을 조건부 확률의 곱으로 미리 계산한다

### 변수 트리




### 조건부 확률표 예시 $P(P_2 \mid P_1)$

| $P_1$ 값 | $P_2$ = 0 | $P_2$ = 1 | $P_2$ = 2 | $P_2$ = 3 |
|---|---|---|---|---|
| 0 | 0.1 | 0.4 | 0.2 | 0.3 |
| 1 | 0.5 | 0.1 | 0.25 | 0.15 |
| 2 | 0.2 | 0.3 | 0.4 | 0.1 |
| 3 | 0.05 | 0.15 | 0.3 | 0.5 |

모집단 seed를 바꾸면 표도 바뀐다

- 변수 8개, 각 변수는 0, 1, 2, 3 중 하나의 값을 가진다. 확률표는 Dirichlet(1)에서 (조건부로) 뽑는다
- 잎 $L_i$는 자기 부모 $P_i$에만 의존하고 나머지와는 조건부 독립이다. $P_2$를 알면 $P_1$과 $P_3$은 조건부 독립이다
- 조건부 독립 덕분에 각 셀 확률을 곱으로 계산할 수 있어, 가능한 모든 셀의 참 확률을 미리 구해 둔다

**트리 구조로 변수 간 의존성을 두면서도 셀별 참 확률을 정확히 알 수 있다**

# STZ와 Majority 전용 0 설계

부모 쌍마다 저확률 조합 하나를 양쪽 클래스에서 금지(STZ)하고, 두 쌍에는 majority 전용 0을 둔다

| 부모 쌍 | 공유 0 (STZ) | Majority 전용 0 (Z) |
|---|---|---|
| $(P_1, P_2)$ | (0, 2) | — |
| $(P_1, P_3)$ | (1, 3) | — |
| $(P_1, P_4)$ | (2, 0) | (3, 1) |
| $(P_2, P_3)$ | (0, 1) | — |
| $(P_2, P_4)$ | (1, 2) | (0, 3) |
| $(P_3, P_4)$ | (3, 0) | — |

**규칙**

- 공유 0: 각 부모 쌍의 16개 값 조합 중 확률 ≤ 0.05인 후보에서 하나씩 고른다 (총 6개). 양쪽 클래스 모두 금지
- Majority 전용 0: 부모 쌍 2개를 더 골라 하나씩 지정한다. minority에서는 가능하며 영역 Z를 이룬다
- 둘 다 아닌 셀은 영역 R(양쪽 모두 가능)에 속한다

**STZ는 양쪽 클래스에서 금지, Z는 minority에서만 가능한 영역이다**

# 금지 쌍 심기: Majority 발생 확률 조절

## 잎 조건부 확률을 직접 정해 금지 쌍의 majority 확률을 목표값 $t$ = 0.06으로 맞춘다

### 규칙

- 잎 간선 $i$마다 $a_i' = \arg\max_v P_0(P_i = v)$를 두고, 잎 값 $a$를 하나 무작위로 고른다

$$P(L_i = a \mid P_i = a_i') = t / P_0(P_i = a_i')$$

- 잎은 부모가 주어지면 나머지와 독립이므로 금지 쌍 $(P_i = a_i', L_i = a)$의 $\pi_0$는 정확히 $t$가 된다
- 금지 쌍은 잎 간선 4개에 하나씩, 환경마다 4개다
- 손실 비율 $e = t/P_0(a_i')$. Frequent는 $e \le 0.2$(Floor 가정 조건)를 지키려고 $P_0(a_i') \ge 0.3$이 아니면 seed를 거절한다
- 무작위 표에서 금지 쌍을 찾는 방식은 seed 300개에서 수락 0%였다

### 예시

| 부모 값 $v$ | 0 | 1 | 2 | 3 |
|---|---|---|---|---|
| $P_0(P_1 = v)$ | 0.1 | 0.25 | **0.45** | 0.2 |

- $a_1'$ = 2, $P_0(P_1 = 2)$ = 0.45
- 목표 $P_0(P_1 = 2, L_5 = 1)$ = 0.06이므로 $P(L_5 = 1 \mid P_1 = 2)$ = 0.06 / 0.45로 둔다
- 수정한 확률표를 정규화해 $p_0$를 완성하고 8000행을 샘플링한다

※ 이해를 돕기 위한 예시 값

**금지 쌍의 majority 출현 확률을 $t$로 고정해 STZ 인증 난이도를 조절한다**

# Minority 분포: 금지 셀의 질량 이동

$p_0$에서 출발해 금지 쌍의 질량을 부모 값만 바꾼 셀로 옮겨 $p_1^{\text{base}}$를 만든다




### 금지 셀 질량 이동 예시

| 셀 | 기존 확률 | Minority 금지 적용 후 |
|---|---|---|
| $(P_1 = 2, L_5 = 1)$ | 0.06 | **0** |
| $(P_1 = 0, L_5 = 1)$ | 0.1 | 0.12 |
| $(P_1 = 1, L_5 = 1)$ | 0.08 | 0.1 |
| $(P_1 = 3, L_5 = 1)$ | 0.12 | 0.14 |

- majority와 minority가 일정 부분 연관되어 있다는 가정에 따라 $p_0$를 출발점으로 쓴다
- 금지 쌍은 minority에서 확률 0이 되어야 하므로, 그 질량을 금지 쌍의 부모 변수 값만 바꾼 셀로 옮기고 나머지 변수 값은 유지한다
- 이 과정을 거친 분포를 $p_1^{\text{base}}$로 둔다

※ 이해를 돕기 위한 예시 값

**$p_1^{\text{base}}$는 $p_0$와 같은 영역에만 질량이 있고 Z에는 질량이 없다**

# Minority 분포: Z 영역에 질량 부여

별도 트리 $h$를 R과 Z에서 정규화해 $p_1^{\text{base}}$와 섞고, $\gamma$로 Z 질량을 정한다

$$p_1(c) = 0.8\, p_1^{\text{base}}(c) + 0.2\gamma\, h(c \mid Z) + 0.2(1-\gamma)\, h(c \mid R)$$

- $p_1^{\text{base}}$는 majority 분포에서 출발했으므로 Z에 질량이 없다
- Z에 확률을 주기 위해 새 트리 $h$를 도입한다. 처음과 같이 Dirichlet(1)에서 확률표를 만들고 R과 Z 각각에서 정규화해 $h(\cdot \mid R)$, $h(\cdot \mid Z)$를 얻는다
- 모든 셀의 확률과 소속(R, Z, STZ)을 알기 때문에 해당 영역이 아닌 셀은 0으로 둔다

| 환경 | R (majority에도 가능) | Z (minority에만 가능) |
|---|---|---|
| Fav | 약 10,000행 (100%) | 0행 (0%) |
| Avg | 약 9,000행 (90%) | 약 1,000행 (10%) |
| Unf | 약 8,000행 (80%) | 약 2,000행 (20%) |

겹침 환경별 R·Z 질량

**Z 질량 0%, 10%, 20%로 majority–minority 겹침 수준을 바꾼다**

# 실험 세팅

쉬운 상황(Frequent)에서 겹침 3수준 × $n_1$ 2수준 × 모집단 3 × 표본 10 = 180칸을 돌린다

| 축 | 유리 | 중간 | 불리 |
|---|---|---|---|
| STZ 인증 난이도 | **Frequent (6%)** | Mid (3%) | Rare (0.5%) |
| 겹침 (Z에 들어가는 질량) | Fav (0%) | Avg (10%) | Unf (20%) |

이번 실행은 굵게 표시한 Frequent 하나와 겹침 3수준 전부

- 모집단 seed 3개: 서로 다른 모집단 3개를 만든다
- 표본 seed 10개: 모집단 분포를 고정한 채 표본을 10번 뽑는다
- minority 크기 $n_1 \in \{400, 800\}$, majority 크기 $n_0$ = 8000으로 고정한다

**3 환경 × 모집단 seed 3 × 표본 seed 10 × $n_1$ 2개 = 180칸**

# Support Estimation: 세 가지 허용 규칙

pair 관측 여부로 셀 허용을 정하는 세 규칙 중 C가 SZ 회수와 STZ 억제를 함께 지킨다

## Local support 가정

| 관측 행 | $X_1$ | $X_2$ | $X_3$ |
|---|---|---|---|
| 가 | 0 | 0 | 1 |
| 나 | 0 | 1 | 0 |
| 다 | 1 | 0 | 0 |

- full cell $c$ = (0, 0, 0)이 minority에서 한 번도 관측되지 않아도, $c$를 이루는 pair들의 관측 여부로 허용을 판단한다
- 위 예에서는 세 pair가 모두 관측되었으므로 $c$는 허용된다

| 지표 | A | B | C |
|---|---|---|---|
| SZ 질량 회수 | 98.10% | **99.70%** | **99.70%** |
| SZ 개수 회수 | 86.50% | **96.70%** | **96.70%** |
| STZ 억제 | **100%** | 75.60% | **100%** |

굵게 = 행별 최고

**A** pair가 minority에서 한 번도 안 보였으면 그 패턴을 포함한 모든 셀을 금지한다

**B** minority에서 안 나왔어도 majority에 1회라도 나왔으면 허용한다

**C** majority에서 많이($x^*$ 이상) 나왔는데 minority에서 0번이면 STZ로 보고 금지한다

**Support 추정 단계에서는 규칙 C가 SZ를 거의 모두 허용하고 STZ를 모두 막는다**

# 생성 후 SZ 질량 회수

## Support 추정은 잘했지만 생성 단계에서 BOMiS의 질량 회수는 DL 모델보다 낮다

Frequent (6%), 모집단 seed 3 × 표본 seed 10, $n_0$ = 8000, 평균 ± MCSE (180칸)

| | fav | | avg | | unf | |
|---|---|---|---|---|---|---|
| **방법** | **400** | **800** | **400** | **800** | **400** | **800** |
| BOMiS | 0.424 ± 0.016 | 0.435 ± 0.014 | 0.434 ± 0.020 | 0.453 ± 0.021 | 0.458 ± 0.007 | 0.485 ± 0.008 |
| TabSyn | 0.545 ± 0.021 | **0.499 ± 0.022** | 0.536 ± 0.022 | **0.497 ± 0.022** | **0.601 ± 0.019** | **0.559 ± 0.019** |
| TabDiff | **0.546 ± 0.019** | 0.423 ± 0.020 | **0.539 ± 0.022** | 0.414 ± 0.021 | 0.594 ± 0.023 | 0.465 ± 0.020 |
| TabDDPM | 0.500 ± 0.022 | 0.462 ± 0.029 | 0.497 ± 0.020 | 0.460 ± 0.022 | 0.548 ± 0.023 | 0.532 ± 0.019 |
| CTGAN | 0.426 ± 0.021 | 0.365 ± 0.018 | 0.421 ± 0.024 | 0.359 ± 0.023 | 0.429 ± 0.013 | 0.388 ± 0.014 |

질량 회수 = 생성 행이 덮은 SZ 셀의 확률 질량 (높을수록 좋다). 굵게 = 열별 최고, 열 = 겹침 환경 / $n_1$

- DL 모델의 회수가 높은 것은 STZ도 그만큼 많이 생성했기 때문이다 (leak, 다음 장)

**생성 단계까지 가면 BOMiS의 SZ 회수 성능이 아쉽다**

# 생성 후 SZ 개수 회수

## 개수 회수에서는 BOMiS가 모든 환경에서 가장 낮다

Frequent (6%), 모집단 seed 3 × 표본 seed 10, $n_0$ = 8000, 평균 ± MCSE (180칸)

| | fav | | avg | | unf | |
|---|---|---|---|---|---|---|
| **방법** | **400** | **800** | **400** | **800** | **400** | **800** |
| BOMiS | 0.041 ± 0.002 | 0.053 ± 0.004 | 0.039 ± 0.005 | 0.050 ± 0.006 | 0.030 ± 0.004 | 0.038 ± 0.004 |
| TabSyn | **0.085 ± 0.005** | **0.084 ± 0.004** | **0.076 ± 0.006** | **0.075 ± 0.006** | **0.072 ± 0.006** | **0.068 ± 0.005** |
| TabDiff | 0.080 ± 0.003 | 0.060 ± 0.001 | 0.070 ± 0.004 | 0.051 ± 0.002 | 0.063 ± 0.005 | 0.045 ± 0.002 |
| TabDDPM | 0.059 ± 0.006 | 0.062 ± 0.006 | 0.052 ± 0.006 | 0.055 ± 0.006 | 0.053 ± 0.006 | 0.055 ± 0.005 |
| CTGAN | 0.072 ± 0.007 | 0.069 ± 0.004 | 0.067 ± 0.006 | 0.062 ± 0.005 | 0.061 ± 0.007 | 0.060 ± 0.004 |

개수 회수 = 생성된 서로 다른 SZ 셀 수 / SZ 셀 수 (높을수록 좋다). 굵게 = 열별 최고, 열 = 겹침 환경 / $n_1$

- 발생 확률이 높은 셀은 DL 모델과 비슷하게 회수하지만 확률이 낮은 셀의 회수가 부족하다

**질량보다 개수 관점에서 BOMiS의 약점이 뚜렷하다**

# STZ Leak과 Control

DL 모델은 생성 행의 2~25%를 STZ에 놓고, BOMiS는 모든 환경에서 leak 0을 유지한다

Frequent (6%), 모집단 seed 3 × 표본 seed 10, $n_0$ = 8000, 평균 (180칸)

### Leak (낮을수록 좋다)

| | fav | | avg | | unf | |
|---|---|---|---|---|---|---|
| 방법 | 400 | 800 | 400 | 800 | 400 | 800 |
| BOMiS | **0** | **0** | **0** | **0** | **0** | **0** |
| TabSyn | 0.165 | 0.133 | 0.170 | 0.129 | 0.155 | 0.121 |
| TabDiff | 0.074 | 0.025 | 0.071 | 0.024 | 0.077 | 0.023 |
| TabDDPM | 0.200 | 0.171 | 0.199 | 0.168 | 0.191 | 0.147 |
| CTGAN | 0.247 | 0.241 | 0.247 | 0.237 | 0.235 | 0.233 |

leak = 생성 행 중 $S_1$ 밖(STZ)에 놓인 비율

### Control (높을수록 좋다)

| | fav | | avg | | unf | |
|---|---|---|---|---|---|---|
| 방법 | 400 | 800 | 400 | 800 | 400 | 800 |
| BOMiS | **1.000** | **1.000** | **1.000** | **1.000** | **1.000** | **1.000** |
| TabSyn | 0.776 | 0.794 | 0.770 | 0.799 | 0.783 | 0.800 |
| TabDiff | 0.879 | 0.934 | 0.882 | 0.934 | 0.870 | 0.930 |
| TabDDPM | 0.702 | 0.710 | 0.703 | 0.716 | 0.713 | 0.743 |
| CTGAN | 0.689 | 0.671 | 0.696 | 0.679 | 0.704 | 0.688 |

control = 1 − leak / novel, 새 행 중 가능한 셀에 놓인 비율

**DL 모델의 높은 회수는 STZ leak과 함께 나온다**

# Recovery 회복 방안: 새 셀 수의 상한

새 셀 수 $L = \min(n_{\text{new}}, \hat{N}_{\text{Chao1}})$이 실제 SZ 셀 수보다 작아 개수 회수가 낮아진다

Frequent (6%), $n_1$ = 400 예시

**생성할 행 7,600**
$n_0 - n_1$

→

**Good–Turing 0.665**
새 셀 5,040행 · 기존 셀 2,560행

→

**Chao1 1,150**
새 셀 수 $L$ = min(5,040, 1,150)

→

**셀당 약 4.4행**
5,040 / 1,150

- Good–Turing은 몇 행을 새 셀에 놓을지, Chao1은 서로 다른 새 셀을 몇 종류 만들지 정한다. Chao1은 학습 데이터에서 한 번·두 번 나온 셀 수로 미관측 셀 수를 추정한다
- 실제 minority에는 가능한 셀이 훨씬 많은데 1,150개만 고르므로, support 추정을 아무리 잘해도 회수가 낮아진다
- minority에는 확률이 매우 작은 셀이 많고 관측까지 고려하면 더 희귀해져 Chao1도 추정에 어려움을 겪는다

※ 이해를 돕기 위한 예시 값

**개수 회수의 병목은 support 추정이 아니라 새 셀 수 $L$의 상한이다**

# 상한 해제: $L = n_{\text{new}}$

상한을 해제하면 BOMiS의 질량 회수가 모든 환경에서 가장 높아진다

Frequent (6%), 모집단 seed 3 × 표본 seed 10, $n_0$ = 8000, 평균 ± MCSE (180칸)

| | | BOMiS | | Baselines | | | | |
|---|---|---|---|---|---|---|---|---|
| 환경 | $n_1$ | 원본 | 상한 해제 | TabDDPM | TabSyn | TabDiff | ARF | CTGAN |
| fav | 400 | 0.424 | **0.754 ± 0.022** | 0.500 | 0.545 | 0.546 | 0.508 | 0.426 |
| fav | 800 | 0.435 | **0.693 ± 0.024** | 0.462 | 0.499 | 0.423 | 0.447 | 0.365 |
| avg | 400 | 0.434 | **0.746 ± 0.024** | 0.497 | 0.536 | 0.539 | 0.502 | 0.421 |
| avg | 800 | 0.453 | **0.686 ± 0.028** | 0.460 | 0.497 | 0.414 | 0.443 | 0.359 |
| unf | 400 | 0.458 | **0.812 ± 0.011** | 0.548 | 0.601 | 0.594 | 0.550 | 0.429 |
| unf | 800 | 0.485 | **0.773 ± 0.018** | 0.532 | 0.559 | 0.465 | 0.491 | 0.388 |

SZ 질량 회수. 굵게 = 행별 최고

- 대신 pair TV(생성 품질)가 0.01~0.02 나빠진다. 확률이 희소한 셀까지 많이 생성해 minority 분포를 정확히 재현하는 관점에서는 불리할 수 있다

**목표(SZ를 많이 회수 vs minority 분포 복원)에 따라 $L$을 정하는 규칙이 필요하다**